


AI 생성 콘텐츠 탐지기

404

: HUMAN_NOT_FOUND

SNS 속 AI 생성 인물 이미지와 영상을
3단계로 탐지합니다.

TEAM 이지수 · 신우철 · 박효준 · 진민경 · 김성일



AUDIENCE HOOK

AI일까요, 실제일까요?

채팅창에 AI / REAL을 먼저 받아주세요. 다음 페이지에서 정답을 공개합니다.



질문: 이 인물 사진은 실제일까요, AI가 만든 이미지일까요?

AI / REAL

ANSWER REVEAL

정답: AI로 만든 이미지입니다.

방금 본 사진은 실제 인물이 아니라 AI 생성 이미지입니다.



눈으로만 보면
거의 구분하기
어렵습니다.

그래서 저희는 SNS 속 AI 생성 인물 이미지를
자동으로 탐지하는 서비스를 만들었습니다.

AUDIENCE HOOK

이번 사진은 AI일까요, 실제일까요?

이번에도 채팅창에 AI / REAL을 먼저 받아주세요.



질문: 이 여성 인물 사진은 실제일까요, AI가 만든 이미지일까요?

AI / REAL

ANSWER REVEAL

정답: 실제 사진입니다.

방금 본 사진은 AI 생성 이미지가 아니라 실제 사진입니다.



실제 사진도 AI처럼 보일 수 있습니다.

결국 사람의 눈만으로는 AI와 실제를
항상 안정적으로 구분하기 어렵습니다.

YOUTUBE NEWS CLIP

먼저, 뉴스 30초만 보겠습니다.

썸네일이나 재생 버튼을 클릭하면 YouTube 영상이 열립니다. 세 사례를 보며 설명합니다.



늑구 사태

AI 이미지 제보가
실제 수색으로 이어진 사례

영상 재생



가짜 의사 허위광고

AI 전문가 광고가
구매 판단을 흐드는 사례

영상 재생



딥페이크 피해 사례


허위 영상 유포가
실제 피해로 이어진 사례

영상 재생

DATA TARGET

데이터 타겟은 ‘인물 이미지’입니다.

앞에서 본 문제는 AI가 실제인물처럼 보이는 이미지를 만들 때 커집니다.
그래서 모든 AI 이미지가 아니라, 사람이 등장하는 인물 이미지를 데이터 타겟으로 잡았습니다.



즉, 우리의 데이터셋과 성능 평가는 ‘인물 이미지’를 기준으로 설계됩니다.

AUDIENCE RESULT

사람들은 얼마나 헛갈렸을까요?

설문 결과에서도 AI / REAL 구분이 쉽지 않다는 점을 확인할 수 있었습니다.


통계

평균
43.53/100점

중앙값
40/100점

범위
0~100점

총점 분포



GOAL SETTING

목표는 80% 이상으로 잡았습니다.

설문 결과는 평균 43.53점, 중앙값 40점이었습니다.
사람도 헛갈리는 문제이기 때문에,
모델은 최소한 두 배 가까이 높은 기준을 목표로 했습니다.

사람 판별 결과

43.53점

평균 / 100점
중앙값 40점

× 2

인물 판별은
사람보다
확실하게

모델 목표

80%+

인물 이미지 판별 기준
실제 서비스 목표


목표 의미

모델이 사람보다
더 안정적으로
인물 이미지를
구분하는지를 보려했습니다.

사람 평균 43.53점

목표 80%+

이 목표를 기준으로 뒤의 모델 구조와 성능표를 확인합니다.



404

: HUMAN_NOT_FOUND

FIG.01 - DETECTOR MARK

PROJECT WORKFLOW

프로젝트 진행 워크플로우.

문제 정의 → 데이터 준비 → 전처리 → 모델 학습 → 평가 → 배포 및 모니터링

1단계	문제 정의	AI 생성 인물 이미지가 만드는 사회적 문제와 탐지 필요성 정리
2단계	데이터 준비	AI/REAL 인물 이미지 데이터셋 구성과 라벨 확인
3단계	전처리	이미지 크기, 형식, 품질을 정리해 모델 입력 형태로 변환
4단계	모델 학습	후보 모델을 비교하고 최종 앙상블 구조로 학습 및 추론 구성
5단계	평가	정확도, 정밀도, 재현율 등 성능 지표로 결과 검증
6단계	배포 및 모니터링	서비스 흐름에 적용하고 탐지 결과를 지속적으로 점검

이 순서를 기준으로 다음 장부터는 탐지 구조와 검증 결과를 설명합니다.

DATA COLLECTION

데이터를 어떻게 구성했는가?

인물 이미지를 타겟으로 정한 만큼, AI 생성 인물과 실제 인물 사진을 직접 수집해 1:1 데이터셋을 구성했습니다.

AI IMAGE

100장

StyleGAN2 기반 50장
외부 플랫폼 3곳 50장
출처 편향을 줄여 분산 수집

REAL IMAGE

100장

randomuser.me API 100장
실제 인물 프로필만 사용
조건 편향이 없도록 확인


BALANCE

200장

AI : Real = 1 : 1
각 100장으로 구성
클래스 불균형 차단

PREPROCESSING PIPELINE

Stage 2의 PRNU·NIS 통계 분석에 필요한 원천 데이터를 최대한 보존하는 방식으로 설계했습니다.



전처리의 핵심은 단순 리사이즈가 아니라, 통계 분석에 필요한 원천 신호를 보존하는 것입니다.

3-STAGE PIPELINE

API 비용 최소화 + 정확도 극대화.

단계별 필터링으로 비용은 줄이고 Recall은 끌어올립니다.



설계 원칙:스테이지 1,2는 이미지 파일이 갖고 있는 기본 데이터로 API_KEY호출 비용을 최소화 하였습니다.

FREE FILTER · METADATA

1차 필터: 남아 있는 출처 신호를 먼저 확인합니다.

EXIF · C2PA · VideoFACT · FreqNet을 API 호출 전 보조 필터로 활용합니다.

EXIF

카메라 메타

카메라 기종·촬영 정보 등
AI 도구 흔적 확인

C2PA

콘텐츠 서명

출처 디지털 서명 검증
Adobe 등 지원

VideoFACT

WACV 2024

장면 문맥 + 위조 흔적
포렌식 분석

FreqNet

AAAI 2024

주파수 도메인의
AI 특유 패턴 탐지

FREE FILTER · DIFFICULTY SCORE

2차 필터: 실사에 가까운 정도를 난이도 점수로 바꿉니다.

실사 사진에 얼마나 가까운가를 점수를 뽑아보았습니다.

PRNU

Photo Response Non-Uniformity

실제 카메라 이미지 센서의 고유 지문.
AI 생성 이미지에는 없거나
불규칙합니다.

NIS

Natural Image Statistics

자연 사진에서 수학적으로 발생하는
패턴.
AI 이미지는 통계 분포에서 벗어납니다.

난이도 점수

0-1

높을수록 판별이 어려운
이미지

ENSEMBLE MODEL

3차 필터: 두 모델을 6:4로 앙상블했습니다.

인물의 전반적인 구도·실사감과 픽셀 단위의 인공적 질감을 함께 봤습니다.

haywoodsloan

인물의 구도와 실사감 파악에 뛰어난 성능을 보였습니다.

organika

픽셀 단위의 미세한 인공적 질감을 예리하게 잡아내는 강점이 있었습니다.

haywoodsloan 60% + organika 40% → Soft Voting

두 모델의 예측 값을 비율로 결합해 최종 판별을 내립니다.

단일 모델 한계 보완

구도와 질감 신호를 함께 반영

6가지 지표 개선

Accuracy·Precision·Recall·F1·FPR·Time

METRICS GUIDE

어떠한 항목을 성능지표로 선정하였는가?

모든 지표는 TP·TN·FP·FN 혼동 행렬에서 계산되며, 단일 지표만 보면 성능을 오해할 수 있습니다.

01

Accuracy · 정확도

 $(TP + TN) / \text{전체}$

목표 80% 이상
전체 이미지 중 모델이 맞힌 비율

02

Precision · 정밀도

 $TP / (TP + FP)$

목표 75% 이상
모델이 AI라고 한 것 중 실제 AI 비율

03

Recall · 재현율 ★

 $TP / (TP + FN)$

목표 80% 이상
실제 AI 이미지 중 모델이 잡아낸 비율

04

F1 Score · 균형 성능

 $2 \times (P \times R) / (P + R)$

목표 70% 이상

Precision과 Recall의 조화평균

05

FPR · 오탐률

 $FP / (FP + TN)$

목표 20% 이하

실제 이미지를 AI로 잘못 판정한 비율

06

Inference Time · 추론 속도

이미지 1장 처리 시간

목표 3초 이하

서비스에서 사용 가능한 응답 속도

판단 흐름: Recall을 먼저 확인하고, F1·Precision·Accuracy·FPR·Time을 함께 봅니다.

PERFORMANCE COMPARISON

최종 앙상블 모델을 기준으로 비교했습니다.

기존 후보 모델과 SIDA를 한 표에 놓고, Recall·정확도·속도를 함께 봤습니다.

모델	Acc.	Prec.	Recall	F1	FPR	Time	비고
최종 앙상블 (우리 모델)	90.0%	78.0%	91.1%	84.0%	10.5%	0.69s	최종 채택
ai-image-detector-deploy	88.3%	75.9%	87.1%	81.1%	11.3%	0.83s	구성 요소
sdxl-detector	77.1%	59.1%	67.3%	63.0%	18.9%	0.45s	구성 요소
AI-image-detector	26.36%	5.68%	9.90%	7.22%	66.94%	0.566s	후보
Deep-Fake-Detector-Model	30.66%	17.81%	38.61%	24.38%	72.58%	0.257s	후보
SIDA-7B	70.0%	47.0%	29.0%	36.0%	27.3%	0.79s	후보

선택 이유: Recall 91.1%, Accuracy 90.0%, 평균 0.69초로 가장 균형적입니다.

90.0%
Accuracy

91.1%
Recall

0.69s
Avg Time

AI는 도구, 속임수는 문제입니다.

AI 생성 이미지는 재미와 감동을 주는 도구가 될 수 있습니다.
하지만 누군가를 속이는 수단이 되어서는 안 됩니다.

Q&A

구현 과정과 결과 지표를 중심으로 답변합니다.

