InSIGHT

AI 가상인물 판독 서비스 기획서 v0.1

생성형 AI의 급격한 발전으로 누구나 실제처럼 보이는 가상 인물을 만들어낼 수 있는 시대가 왔습니다. InSIGHT는 이미지 또는 영상 속 인물이 AI가 만들어낸 가상인물인지, 실제 인물인지를 자동으로 판별해주는 AI 탐지 서비스입니다. 딥페이크 피해와 허위 프로필, 각종 사기로부터 디지털 신뢰를 회복하는 것이 InSIGHT의 핵심 사명입니다.

INSIGHT 팀

2026-04-24

V0.1 DRAFT

Made with GAMMA

서비스 배경 및 필요성

생성형 AI 기술(DALL-E, Stable Diffusion, Midjourney, Sora 등)의 급격한 발전은 디지털 세계에 전례 없는 도전을 가져왔습니다. 오늘날 누구나 손쉽게 실제 인물과 구분하기 어려운 가상 인물 이미지나 영상을 생성할 수 있습니다. 이로 인해 딥페이크 피해, 허위 인물 프로필을 이용한 사기, 온라인 신원 도용 등 심각한 사회적 문제가 빠르게 심화되고 있습니다.

일반 사용자가 육안으로 AI 생성물을 판별하기는 점점 더 어려워지고 있습니다. AI 생성 기술이 발전할수록 생성 결과물의 완성도는 높아지고, 기존의 단순한 시각적 단서들은 점점 의미를 잃어가고 있습니다. 이러한 상황에서 신뢰할 수 있는 자동화된 탐지 도구의 필요성은 그 어느 때보다 절실합니다. InSIGHT(404: Human Not Found)는 바로 이 간극을 채우기 위해 탄생했습니다.

🎭 딥페이크 피해

실제 인물의 얼굴을 합성한 가짜 영상으로 인한 명예훼손 및 범죄 피해가 급증

👤 허위 인물 프로필

AI로 생성된 가짜 프로필 사진을 사용한 사기 계정이 소셜미디어에 범람

🔍 판별 불가 상황

생성 AI 기술의 발전으로 일반인의 육안 판별이 사실상 불가능한 수준 도달

⚖️ 사회적 신뢰 위기

디지털 콘텐츠에 대한 신뢰 붕괴로 정보 생태계 전반의 신뢰성 훼손

Made with GAMMA

개발 단계 로드맵

InSIGHT는 단계적 접근을 통해 완성도 높은 서비스를 구축합니다. 이미지 탐지에서 시작하여 아키텍처를 확정하고, 최종적으로 동영상 탐지까지 확장하는 3단계 로드맵을 채택했습니다. 각 단계는 이전 단계의 학습과 성과를 기반으로 하여 리스크를 최소화하면서 기능을 확장해 나갑니다.

1 → 2 → 3

Phase 1

이미지 AI 탐지기

이미지 입력 → AI 가상인물 여부 판별. Accuracy 70% 이상, Recall 75% 이상 목표. Gradio 기반 웹앱 산출물.

Phase 2

기획서 고도화 및 아키텍처 확정

Phase 1 테스트 결과로 구조 파악 완료. 모델 성능 비교 기반 최종 모델 선정 및 파이프라인 문서화.

Phase 3

동영상 AI 탐지기 확장

이미지 탐지 기반 위에 영상 확장. 프레임 추출, 시간적 일관성 분석, 오디오 위조 탐지 추가.

ⓘ 현재 개발 중인 단계는 **Phase 1 — 이미지 AI 탐지기**입니다. 동영상 대비 디버깅이 수월하고 데이터 확보가 용이한 이미지부터 시작하여 안정적인 기반을 구축합니다.

Made with GAMMA

서비스 아키텍처 — 전체 처리 흐름

InSIGHT의 아키텍처는 비용 효율성과 탐지 정확도를 동시에 달성하기 위해 이중 필터링 구조로 설계되었습니다. 1차 필터링은 API 비용 없이 메타데이터와 워터마크 분석만으로 일부 이미지를 즉시 판별하고, 나머지 이미지만 2차 AI 모델 필터링으로 넘깁니다. 이 구조를 통해 API 호출 비용을 절감하면서도 처리 속도를 높이는 이중 효과를 얻을 수 있습니다.

📥 사용자 이미지 입력

사용자가 판별을 원하는 이미지를 업로드합니다. Gradio 기반 웹 인터페이스를 통해 누구나 쉽게 접근할 수 있습니다.

🔎 1차 필터링 — 무료 레이어

C2PA 메타데이터 검사: AI 생성 서명 존재 시 즉시 "AI 생성" 판정. **SynthID 패턴 탐지:** FFT 주파수 분석으로 인공 워터마크 패턴 감지 시 "AI 의심" 판정. API 비용 없이 처리하는 자체 검열 단계.

🤖 2차 필터링 — AI 모델 레이어

1차에서 판별 불가한 경우에만 진행. 객체 탐지로 얼굴/인물 영역을 먼저 탐지한 후, AI 생성 판별 모델이 해당 영역을 정밀 분석합니다.

📊 최종 결과 출력

판정 결과(AI 가상인물 / 실제 인물), 확률 수치(%), 6가지 성능 지표를 함께 제공하여 투명하고 신뢰할 수 있는 판독 결과를 제시합니다.

Made with GAMMA

기술 스택

InSIGHT는 Python 생태계의 검증된 라이브러리와 최신 딥러닝 프레임워크를 기반으로 구축됩니다. 각 기술 컴포넌트는 서비스의 목적과 성능 목표에 최적화되어 선택되었으며, 오픈소스 기반의 투명하고 확장 가능한 스택을 지향합니다.

언어 및 프레임워크

Python 3.10+
메인 개발 언어

Gradio
웹앱 UI 인터페이스

PyTorch
ML 프레임워크

HuggingFace
Transformers 모델

이미지 처리 및 수치 연산

OpenCV
이미지 처리

PIL/Pillow
이미지 입출력

NumPy
수치 연산 / FFT

SciPy
과학적 연산

1차 필터링 핵심 기술

C2PA 메타데이터 검사

c2pa-python 라이브러리를 활용합니다. 어도비, 구글 등이 주도하는 AI 생성물 표준 디지털 서명을 확인하여 메타데이터에 AI 생성 서명이 포함된 이미지를 즉각 판정합니다.

SynthID 패턴 탐지

NumPy FFT(고속 푸리에 변환)를 사용합니다. 이미지 주파수 도메인에서 AI 생성 워터마크 패턴을 탐지하며, Peak-to-Average Ratio 방식으로 비정상적 주파수 피크를 감지합니다.

개발 협업 체계

GitHub를 통한 버전 관리를 기본으로 합니다. 개인 feature 브랜치에서 각자 개발한 후 성능을 비교하고 최적의 결과를 채택하는 브랜치 전략을 운용합니다.

Made with GAMMA

AI 모델 후보 비교

2차 필터링의 핵심인 AI 판별 모델은 베이스라인 성능 측정 이후 최종 선정됩니다. 현재 4가지 후보 모델을 검토 중이며, 각 모델은 서로 다른 특성과 장단점을 가지고 있습니다. 베이스라인 측정은 파인튜닝 없이 사전 학습 모델 그대로 테스트하여 6가지 성능 지표를 기록하는 방식으로 진행됩니다.

후보 모델	특징	우선순위	파인튜닝 필요
umm-maybe/AI-image-detector	ViT 기반, HuggingFace 제공, 즉시 사용 가능	1순위 ⭐	불필요
Swin Transformer	고성능 이미지 분류 특화, 높은 표현력	2순위	필요
EfficientNet-B4	경량화 모델, 추론 속도 빠름, 실용적	3순위	필요
CNNDetection	CNN 기반 딥페이크 탐지 특화 모델	4순위	필요

모델 최종 선정은 베이스라인 측정 결과를 기반으로 이루어집니다. 성능이 우수하더라도 추론 속도가 3초를 초과하는 모델은 서비스 요건을 충족하지 못할 수 있으므로, 정확도와 속도의 균형을 함께 고려합니다.

Made with GAMMA

AI 학습 지도 파이프라인

InSIGHT의 모델 학습은 체계적인 6단계 파이프라인을 통해 진행됩니다. 데이터 수집부터 최종 평가까지 각 단계가 유기적으로 연결되어 있으며, 목표 지표 미달 시 Step 3~5를 반복하는 피드백 루프를 통해 지속적으로 모델 성능을 개선합니다. 데이터의 균형과 품질이 최종 모델 성능을 결정짓는 핵심 요소입니다.

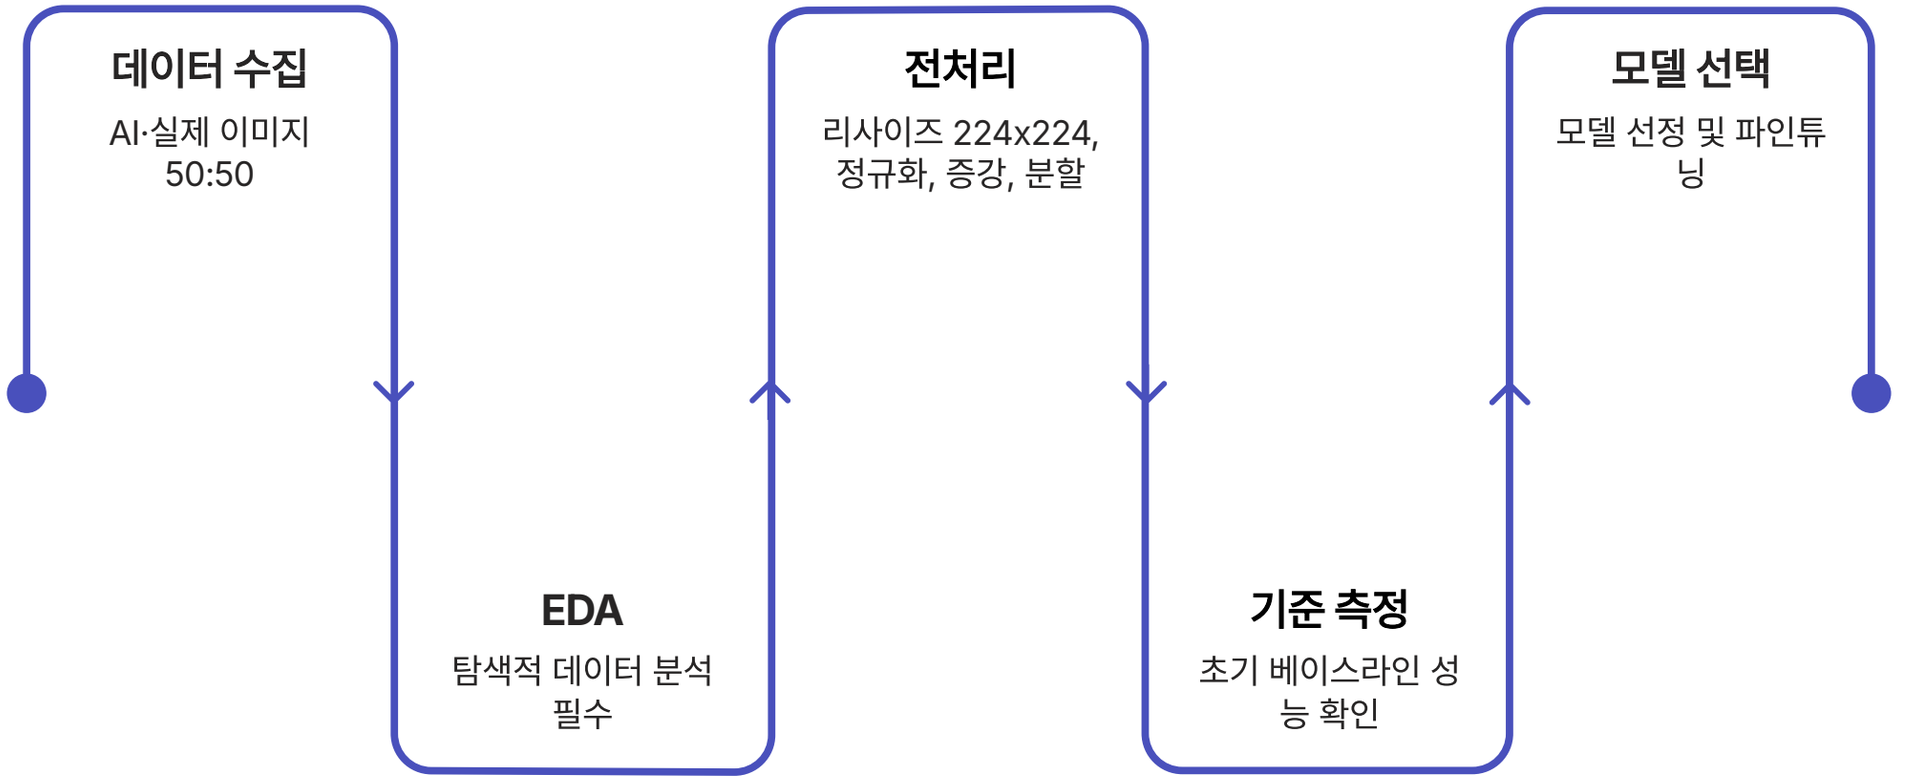

파이프라인의 핵심은 **EDA(탐색적 데이터 분석)**를 학습 전 필수 단계로 위치시킨 것입니다. 클래스 비율, 이미지 해상도 분포, AI 생성 도구별 분포를 사전에 확인하고 이상 데이터를 제거함으로써 학습 데이터의 품질을 보장합니다. 데이터 분할은 Train 70% / Validation 15% / Test 15%로 구성되며, 목표 데이터 비율은 AI 이미지 50% : 실제 이미지 50%의 균형을 유지합니다.

Made with GAMMA

성능 목표 지표

InSIGHT Phase 1의 성능 목표는 실제 서비스 맥락에서 중요도를 반영하여 우선순위가 설정되었습니다. 단순히 전체 정확도보다, 서비스의 핵심 리스크인 "AI 가상인물을 실제로 통과시키는 오류"를 최소화하는 것에 가장 높은 우선순위를 부여했습니다. 이는 서비스의 신뢰성과 직결되는 전략적 판단입니다.

> Recall이 1순위인 이유: AI 가상인물을 "실제"로 통과시키는 것이 서비스에서 가장 치명적인 오류이기 때문입니다. 미탐(False Negative)은 서비스 신뢰를 근본적으로 훼손합니다.

75%

Recall (재현율)

1순위 ★ — AI 가상인물 미탐 방지의 핵심 지표

70%

F1 Score

2순위 — Precision과 Recall의 조화 평균

75%

Precision (정밀도)

3순위 — 오탐(False Positive) 최소화

70%

Accuracy (적중률)

4순위 — 전체 예측 정확도

20%

FPR (오탐률)

5순위 — 20% 이하 유지 목표

3초

Inference Time

6순위 — 3초 이하 응답 속도

Made with GAMMA

향후 과제 및 미결 사항

현재 InSIGHT 팀이 해결해야 할 핵심 미결 사항들과 팀장 검토 요청 항목들을 정리합니다. 이 항목들은 Phase 1 개발을 완료하고 Phase 2, Phase 3로 나아가기 위해 반드시 확정되어야 하는 결정들입니다. 각 항목의 진행 상황을 지속적으로 추적하여 개발 일정에 차질이 없도록 관리합니다.

📋 미결 사항

- ▢ 2차 필터링 최종 모델 선정 (베이스라인 측정 후)
- ▢ 학습 데이터셋 구성 비율 및 출처 확정
- ▢ Phase 1 → Phase 3 전환 기준 지표 값 확정
- ▢ 서비스 배포 환경 결정 (로컬 / 클라우드 / HuggingFace Spaces)

🔍 팀장님 검토 요청

→ 아키텍처 방향성 (1차+2차 필터링 구조) 적절한지 확인

→ 모델 후보 리스트 추가 제안 여부

→ 데이터셋 수집 방향 가이드

⚠ 배포 환경 결정은 서비스 아키텍처 및 비용 구조에 직접적인 영향을 미칩니다. Phase 1 완료 전에 로컬, 클라우드, HuggingFace Spaces 중 최적의 환경을 팀 내에서 합의하여 결정할 필요가 있습니다.

Made with GAMMA

InSIGHT 요약 및 핵심 가치

InSIGHT는 AI 생성 가상인물의 범람이라는 새로운 사회적 문제에 기술로 대응하는 서비스입니다. 이중 필터링 아키텍처를 통해 비용 효율성과 탐지 정확도를 동시에 달성하고, 단계적 로드맵을 통해 이미지에서 영상까지 탐지 범위를 확장해 나갑니다. InSIGHT가 추구하는 궁극적인 가치는 디지털 세계에서 인물 정보의 신뢰성을 회복하는 것입니다.

🎯 명확한 목적

AI 가상인물 vs 실제 인물 자동 판별이라는 단일하고 명확한 서비스 목적을 가집니다.

💡 스마트 아키텍처

1차(무료)+2차(AI 모델) 이중 필터링으로 비용과 성능을 동시에 최적화합니다.

📈 단계적 확장

이미지 → 아키텍처 확정 → 영상으로 이어지는 검증된 3단계 로드맵을 따릅니다.

🛡️ 신뢰 회복

Recall 최우선 원칙으로 서비스의 핵심 신뢰성을 지키는 성능 전략을 취합니다.

> InSIGHT 팀 | 기획서 v0.1 | 2026-04-24 — 디지털 세계의 신뢰를 지키는 눈, InSIGHT

Made with GAMMA