InSIGHT 팀 AI 모델 성능 지표 기록 가이드라인

매 실험마다 동일한 기준으로 성능을 측정하고 기록하여 팀 전체가 같은 언어로 소통하기 위한 공식 가이드라인입니다. 이 문서는 InSIGHT 팀 전체 팀원을 대상으로 하며, AI 이미지 탐지 모델의 성능을 체계적으로 평가하고 개선하는 데 필요한 모든 절차를 다룹니다.

INSIGHT 팀 내부 가이드라인

2026-04-24

Made with GAMMA

왜 지표를 기록해야 하는가?

AI 모델은 "잘 됐다", "안 됐다"로 평가하면 안 됩니다. 숫자로 기록해야 비교할 수 있고, 비교해야 개선할 수 있습니다. 지표를 기록하지 않으면 어떤 변경이 모델을 좋게 만들었는지 알 수 없습니다. 실험 간 일관된 측정 기준이 없으면, 팀원 간 소통이 불일치하고 개선 방향을 잃게 됩니다.

성능 지표는 단순한 숫자가 아니라, 모델이 실제 서비스 환경에서 얼마나 신뢰할 수 있는지를 보여주는 언어입니다. 팀 전체가 동일한 기준으로 측정하고 기록해야만 실험 결과를 올바르게 비교하고, 더 나은 모델로 나아갈 수 있습니다.

📊 측정

숫자로 기록해야 비교 가능

🔁 비교

비교해야 개선 방향 파악

🚀 개선

개선해야 서비스 신뢰도 확보

> 성능 지표 없이는 "더 좋아졌다"는 말도 증명할 수 없습니다. 모든 실험은 기록에서 시작됩니다.

Made with GAMMA

1단계

혼동 행렬 — 모든 지표의 기초

모델이 이미지를 판정할 때 나올 수 있는 결과는 총 4가지입니다. 이 4가지 경우를 정리한 것이 혼동 행렬(Confusion Matrix)이며, 모든 성능 지표는 이 혼동 행렬에서 계산됩니다. 모든 실험에서 아래 4개 수치를 반드시 기록하세요.

	실제: AI이미지	**실제: 실제이미지**
모델 판정: AI	TP (맞음) ✅	FP (오탐) ⚠️
모델 판정: 실제	FN (미탐) ❌	TN (맞음) ✅

TP — True Positive

AI이미지를 AI라고 **올바르게** 판정한 수

TN — True Negative

실제이미지를 실제라고 **올바르게** 판정한 수

FP — False Positive

실제이미지를 AI라고 **잘못** 판정한 수 (오탐)

FN — False Negative

AI이미지를 실제라고 **잘못** 판정한 수 (미탐 — 가장 위험)

⊗ FN(미탐)은 가장 위험한 오류입니다. AI 생성 이미지가 실제 이미지로 통과되면 서비스 신뢰도가 붕괴됩니다. 모든 실험에서 FN을 최소화하는 것이 핵심입니다.

Made with GAMMA

2단계

6가지 필수 성능 지표

혼동 행렬의 4개 수치(TP, TN, FP, FN)를 바탕으로 아래 6가지 성능 지표를 반드시 계산하고 기록해야 합니다. 각 지표는 서로 다른 관점에서 모델의 성능을 측정하므로, 단일 지표만 보는 것은 위험합니다. 반드시 6가지 모두를 함께 분석하세요.

1

Accuracy — 정확도

공식: (TP + TN) ÷ 전체 × 100

팀 목표: 70% 이상

전체 이미지 중 모델이 맞힌 비율. 데이터 불균형 시 단독으로 신뢰 불가.

2

Precision — 정밀도

공식: TP ÷ (TP + FP) × 100

팀 목표: 75% 이상

모델이 "AI"라고 했을 때 실제로 AI인 비율. 낮으면 오탐 증가 → 사용자 불만.

3

Recall — 재현율 ★핵심

공식: TP ÷ (TP + FN) × 100

팀 목표: 75% 이상

실제 AI이미지 중 모델이 잡아낸 비율. 낮으면 AI가 실제로 통과 → 서비스 신뢰도 붕괴.

4

F1 Score — 균형 성능

공식: 2 × (P × R) ÷ (P + R) × 100

팀 목표: 70% 이상

Precision과 Recall의 조화평균. 두 지표의 균형을 하나의 숫자로 표현.

5

FPR — 오탐률

공식: FP ÷ (FP + TN) × 100

팀 목표: 20% 이하

실제 이미지인데 AI로 잘못 판정한 비율. 낮을수록 좋음. 사용자 경험에 직결.

6

Inference Time — 추론 속도

단위: 초(sec) / Python time 모듈

팀 목표: 3초 이하

이미지 1장 처리 시간. 3초 이하: 실사용 가능 / 3~10초: 개선 필요 / 10초 이상: 서비스 불가.

Made with GAMMA

지표별 심층 이해 — Recall과 F1 Score

6가지 지표 중 팀에서 가장 중요하게 다뤄야 할 두 지표, Recall과 F1 Score에 대해 깊이 이해해야 합니다. 이 두 지표는 서비스 품질과 신뢰도를 결정짓는 핵심 척도입니다.

★ Recall (재현율) — 최우선 지표

Recall이 낮다는 것은 AI 생성 이미지가 "실제 이미지"로 시스템을 통과하고 있다는 의미입니다. 이는 InSIGHT 서비스의 존재 이유 자체를 무너뜨리는 치명적 오류입니다.

예시: 실제 AI이미지 100장 중 80장 탐지 → Recall 80%

Recall이 50%대라면, Accuracy가 70%를 넘어도 절대 성능 달성으로 인정하지 않습니다.

F1 Score — 균형의 척도

F1 Score는 Precision과 Recall 중 하나만 높고 하나가 낮으면 자동으로 낮게 계산됩니다. 즉, 균형 잡힌 모델만이 높은 F1 Score를 달성할 수 있습니다.

불균형 예시: Precision 90%, Recall 50% → F1 64%

균형 예시: Precision 75%, Recall 75% → F1 75%

F1이 낮다면 두 지표 중 어느 쪽이 끌어내리고 있는지 반드시 원인을 파악해야 합니다.

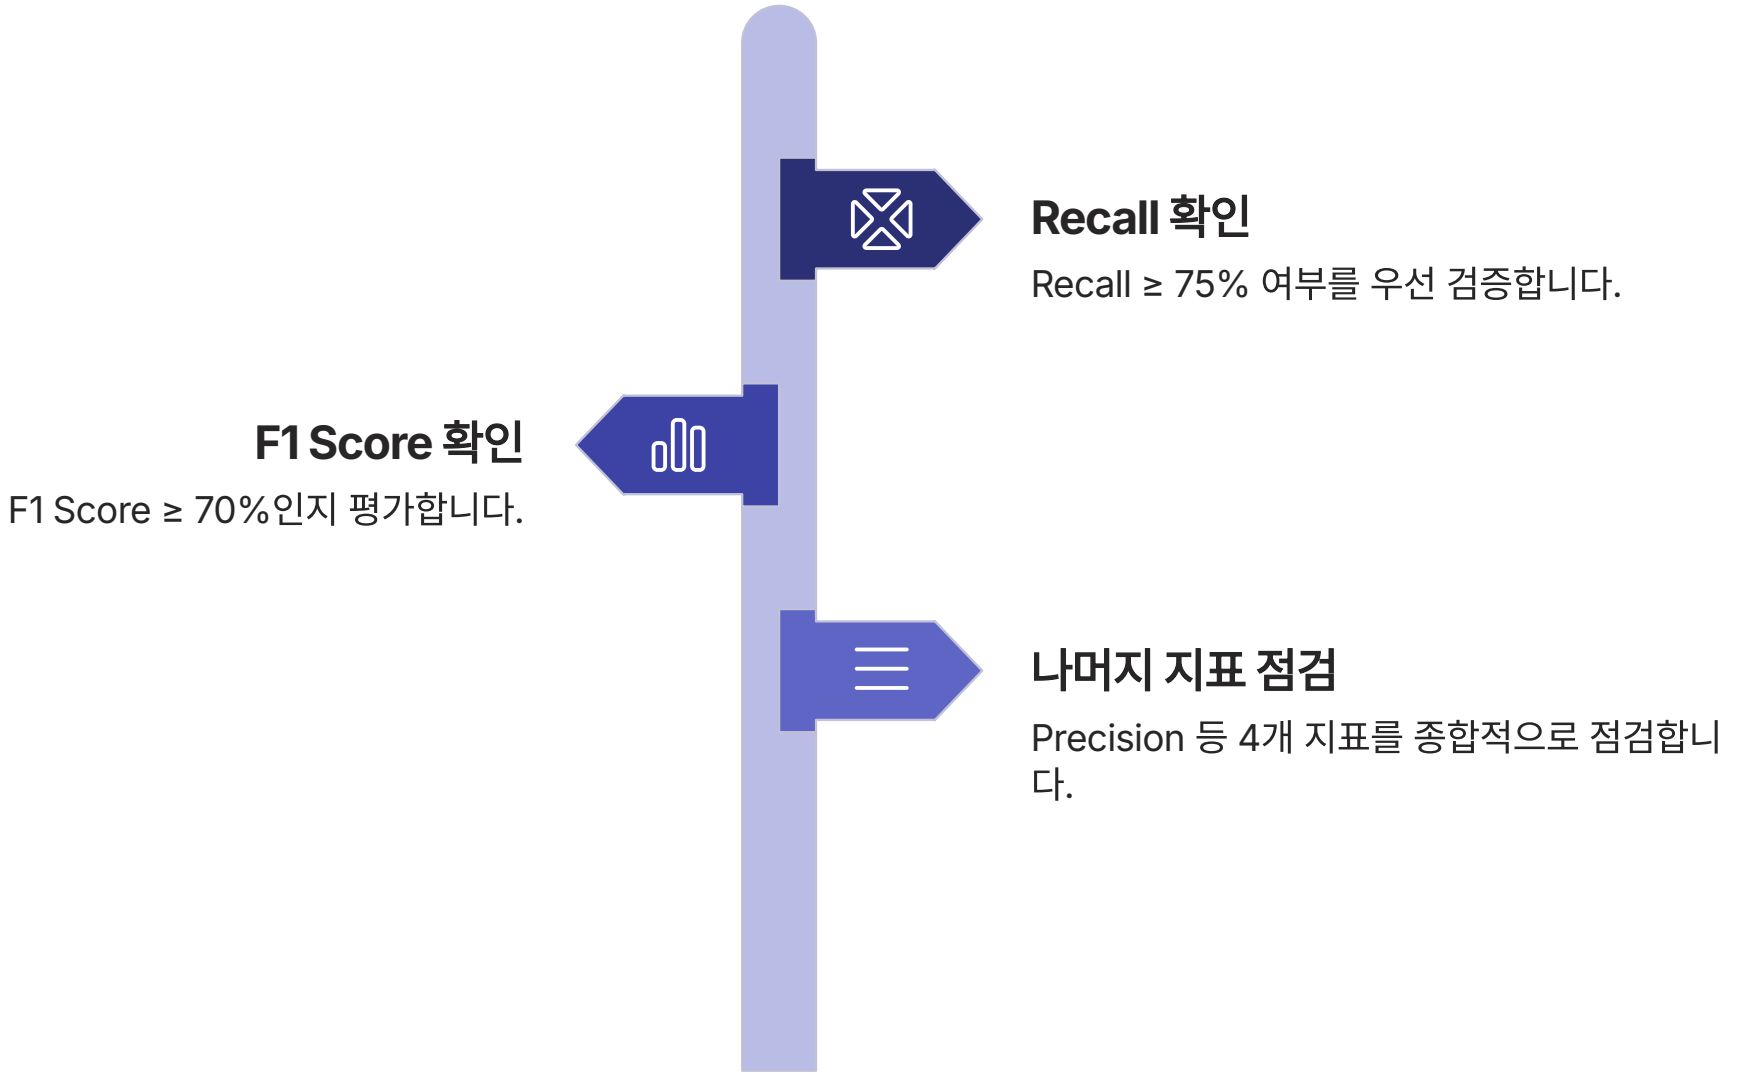

판단 흐름은 항상 Recall 확인에서 시작합니다. Recall이 목표에 미달하면 나머지 지표가 모두 좋더라도 모델 개선이 필요합니다.

Made with GAMMA

3단계

실험 기록 템플릿

매 실험마다 아래 양식을 그대로 복사하여 기록하세요. 실험 기록은 팀 전체의 공유 저장소에 업로드하며, 날짜와 모델 버전이 반드시 포함되어야 합니다. 변경 내용란에는 이전 실험 대비 무엇을 바꿨는지 구체적으로 기술해야 하며, 오류 케이스 분석은 다음 실험 설계에 직접 반영됩니다.

```
========================================
실험 날짜   :
실험자      :
모델 버전   :
변경 내용   : (이전 실험 대비 무엇을 바꿨는지)
테스트 데이터: AI이미지 (  )장 / 실제이미지 (  )장

[ 혼동 행렬 ]
TP: ___  FP: ___  FN: ___  TN: ___

[ 성능 지표 ]
Accuracy     : __%  (목표 70% 이상)
Precision    : __%  (목표 75% 이상)
Recall       : __%  (목표 75% 이상) ★
F1 Score     : __%  (목표 70% 이상)
FPR          : __%  (목표 20% 이하)
Inference Time : __초  (목표 3초 이하)

[ 오류 케이스 분석 ]
FP 주요 패턴: (어떤 실제 이미지가 AI로 오탐됐는지)
FN 주요 패턴: (어떤 AI 이미지가 실제로 미탐됐는지)

[ 종합 의견 ]
잘 된 점:
개선 필요:
다음 실험 계획:
========================================
```

ⓘ 템플릿의 모든 항목은 빠짐없이 작성해야 합니다. 특히 오류 케이스 분석과 다음 실험 계획은 팀 전체 학습에 가장 중요한 부분입니다.

Made with GAMMA

4단계

지표 우선순위 & 판단 기준

6가지 지표는 동등한 가중치를 갖지 않습니다. 우선순위에 따라 어떤 지표가 미달일 때 더 긴급하게 대응해야 하는지가 달라집니다. 아래 표는 팀의 공식 우선순위 기준입니다.

우선순위	지표	목표	낮을 때 문제
1순위 ★	Recall	75% 이상	AI이미지를 실제로 통과시킴 — 서비스 신뢰도 붕괴
2순위	F1 Score	70% 이상	전반적 성능 불균형 — 모델 편향 가능성
3순위	Precision	75% 이상	사용자 오탐 불만 증가 — 사용성 저하
4순위	Accuracy	70% 이상	팀 기본 목표 미달
5순위	FPR	20% 이하	사용자 경험 저하
6순위	Inference Time	3초 이하	서비스 배포 불가

판단 원칙 1

Accuracy 70% 달성해도 Recall이 50% 대면 → **성능 개선 필요**. Recall이 최우선입니다.

판단 원칙 2

6가지 지표 중 하나라도 목표 미달 → **원인 분석 후 다음 실험 설계**. 통과는 없습니다.

판단 원칙 3

모든 지표가 목표 달성 → **영상 탐지기 (Phase 3)로 진행 가능**. 팀 리드에게 보고 후 이동.

Made with GAMMA

지표 목표치 시각화

아래 인포그래픽은 6가지 지표의 목표치와 현재 기준선을 한눈에 비교할 수 있도록 구성하였습니다. 실험 결과를 이 기준과 대조하여 어느 지표가 미달인지 빠르게 파악하세요.

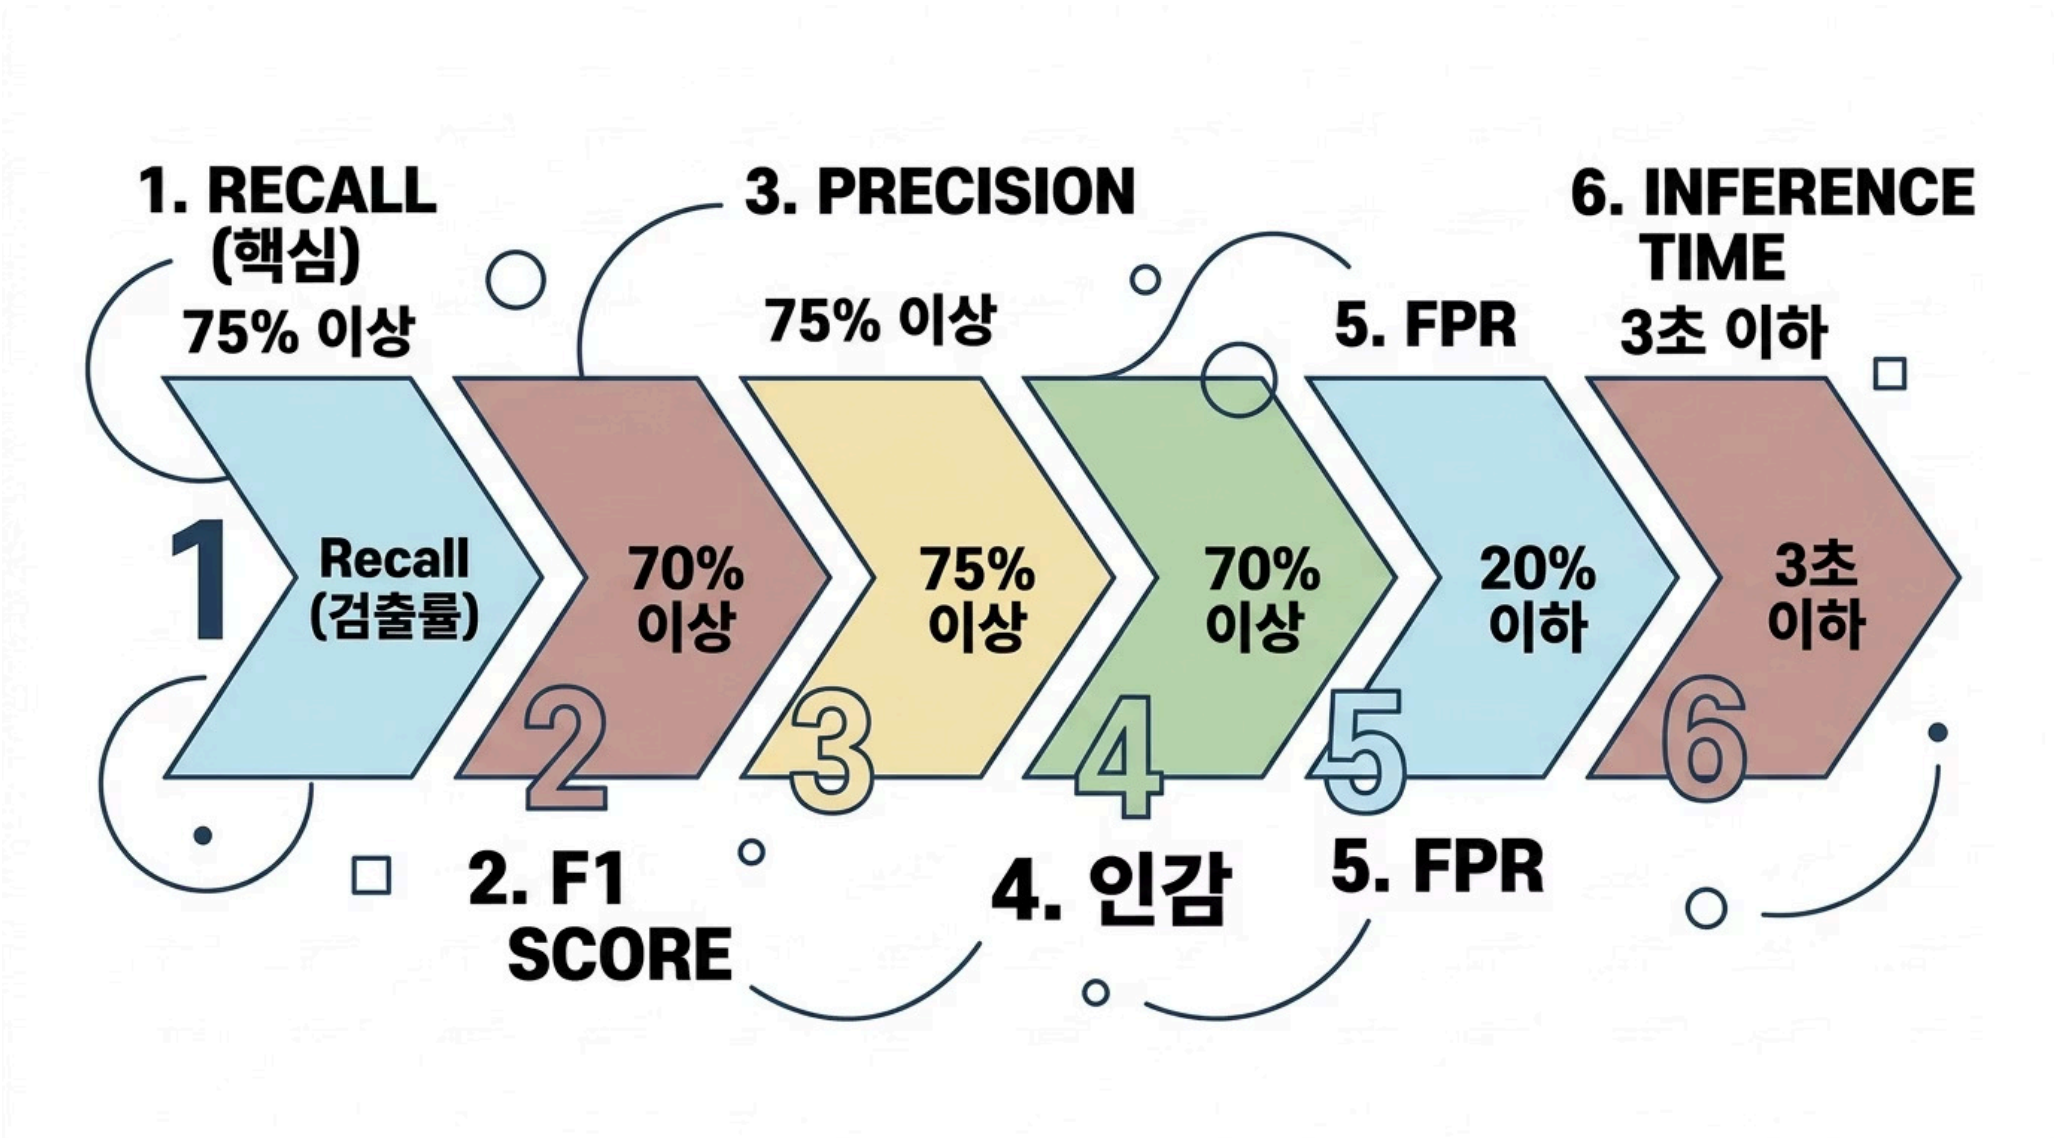

✅ Phase 3 진행 조건

- Recall 75% 이상
- F1 Score 70% 이상
- Precision 75% 이상
- Accuracy 70% 이상
- FPR 20% 이하
- Inference Time 3초 이하

⚠️ 즉시 개선 필요 신호

- Recall 50%대 — 최우선 대응
- F1 Score 60%대 이하 — 불균형 점검
- FPR 30% 초과 — 오탐 원인 분석
- Inference Time 10초 초과 — 배포 불가

Made with GAMMA

5단계

바이브코딩 요청 프롬프트

AI에게 모델 테스트 코드를 요청할 때, 아래 프롬프트를 그대로 복사하여 사용하세요. 이 프롬프트를 사용하면 AI가 6가지 성능 지표를 자동으로 계산하고 팀 표준 형식으로 출력합니다. 매 실험마다 이 형식을 일관되게 사용하는 것이 중요합니다.

아래 코드 블록 전체를 복사하여 AI 코딩 도구(ChatGPT, Claude, Gemini 등)에 붙여넣으세요. 테스트 데이터 경로만 수정하면 됩니다.

```
모델 테스트 실행 후 아래 6가지 성능 지표를 반드시 계산하여 출력해줘.
테스트 데이터는 AI 생성 이미지(Positive)와 실제 이미지(Negative)로 구성되어 있어.

[필수 출력 지표]
1. Accuracy  : (TP + TN) / 전체
2. Precision : TP / (TP + FP)
3. Recall    : TP / (TP + FN) ← 핵심 지표
4. F1 Score  : 2×(Precision×Recall)/(Precision+Recall)
5. FPR       : FP / (FP + TN)
6. Inference Time : time 모듈로 이미지 1장 처리 시간 측정

[출력 형식]
========== 성능 평가 결과 ==========
Accuracy      : 00.00%
Precision     : 00.00%
Recall        : 00.00% ← 핵심
F1 Score      : 00.00%
FPR           : 00.00%
Inference Time : 0.00초
-----------------------------------
TP: 00  FP: 00  FN: 00  TN: 00
====================================
```

이 프롬프트를 그대로 사용하면 팀 전체가 동일한 출력 형식을 받게 됩니다. 실험 기록 템플릿(3단계)에 바로 붙여넣을 수 있는 형태로 출력됩니다.

Made with GAMMA

전체 프로세스 요약 & 다음 단계

이 가이드라인은 InSIGHT 팀이 AI 이미지 탐지 모델을 체계적으로 개선하기 위한 공식 기준입니다. 5단계 프로세스를 반복하면서 모든 지표가 목표를 달성했을 때 비로소 Phase 3(영상 탐지기)로 진행할 수 있습니다.

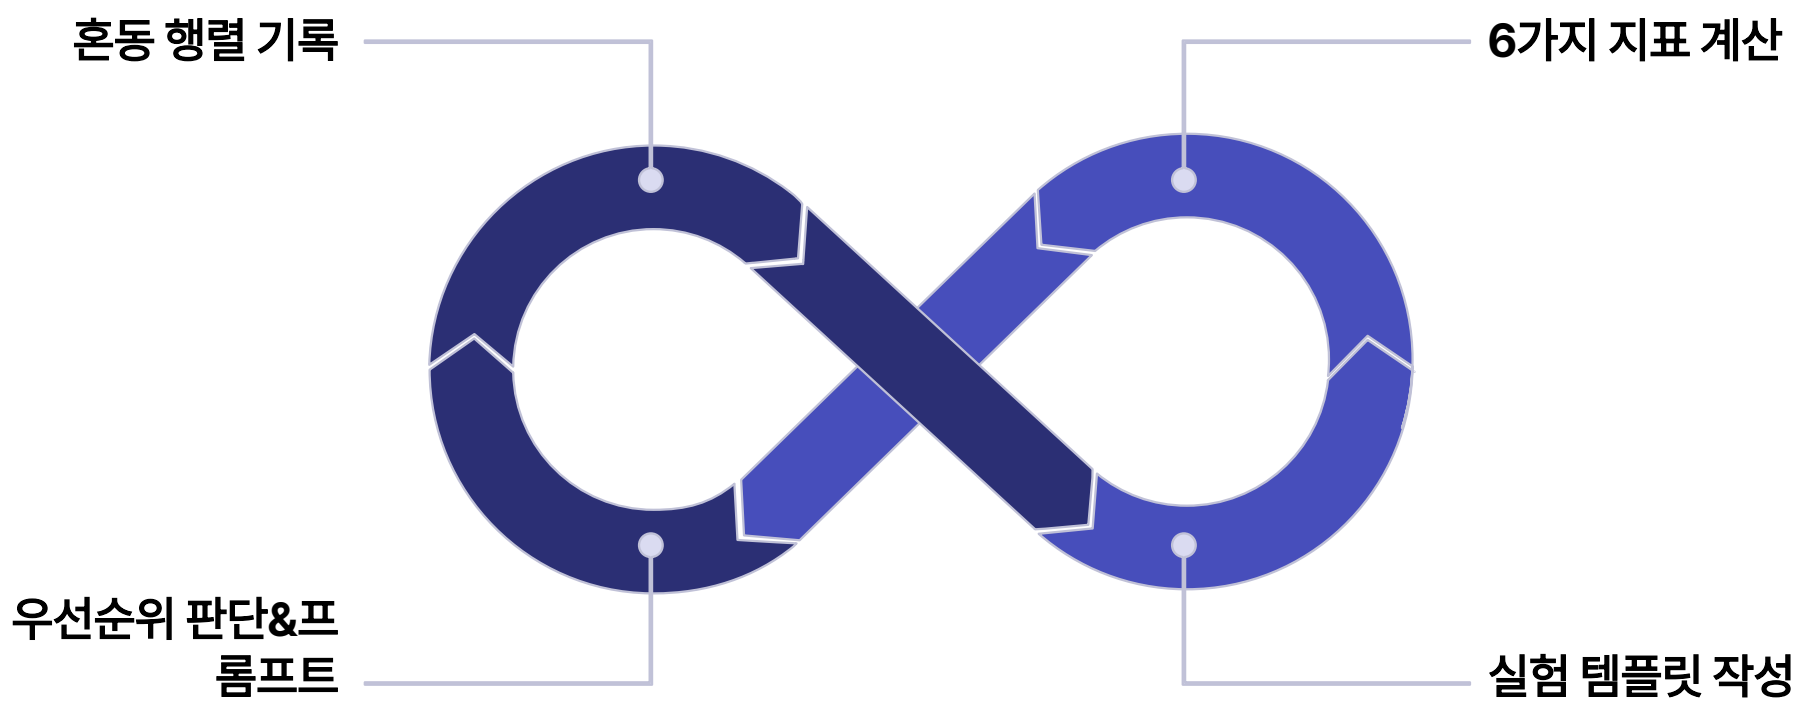

각 실험 후 반드시 팀 공유 저장소에 기록을 업로드하고, 주간 리뷰 미팅에서 지표 트렌드를 함께 분석하세요. 개인 실험이 아닌 팀 전체의 학습이 목표입니다.

🔬 현재 단계	📋 달성 조건	🎯 다음 단계
Phase 2: 이미지 탐지기 성능 최적화	6가지 지표 모두 목표치 달성	Phase 3: 영상 탐지기 개발 착수

✅ 모든 지표가 목표를 달성하면 팀 리드에게 즉시 보고하고, Phase 3 킥오프 미팅을 요청하세요. 이 가이드라인은 InSIGHT 팀의 공식 기준이며, 지속적으로 업데이트됩니다.

Made with GAMMA